

# Previsão de tempo de entrega com Inteligência Artificial

**Guilherme Barrado Pereira, Prof. Dr. Rogério de Oliveira**

Faculdade de Computação e Informática (FCI)  
Universidade Presbiteriana Mackenzie (UPM) – São Paulo – SP – Brasil

32060785@mackenzista.com.br, rogerio.oliveira@mackenzie.br

**Abstract.** *This work explores data extracted from AppGás's sales platform, to build and train traditional supervised machine learning models and deep learning models to predict the delivery time of orders placed within the platform. From the models, it is expected to identify which features are most relevant and their impact on delivery times. The result of each model is compared to choose the best model, allowing the replacement of the methodology currently used by the company.*

**Keywords:** *machine learning, artificial intelligence, prediction, deep learning.*

**Resumo.** *Este trabalho explora dados extraídos da plataforma de vendas da empresa AppGás para construção e treino de modelos de aprendizado de máquina supervisionado tradicionais e modelos de aprendizado profundo, para a previsão do tempo de entrega de pedidos realizados dentro da plataforma. A partir dos modelos, espera-se também identificar as variáveis mais relevantes nos tempos de entrega. Os resultados de cada modelo são comparados propondo-se um modelo final para uso pela empresa.*

**Palavras-chave:** *aprendizado de máquina, inteligência artificial, previsão, aprendizado profundo.*

## 1. Introdução

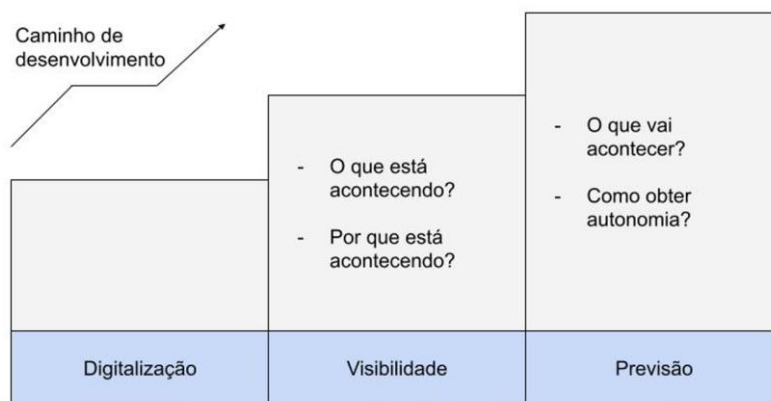
Benke et al. (2016) explica como os recentes avanços nos ramos de ciência de dados e inteligência artificial tiveram um grande impacto em nossa sociedade como um todo. A aplicação de técnicas de inteligência artificial é impulsionada pela quantidade cada vez maior de dados que são gerados, por sistemas, por sensores, dispositivos móveis, etc. O aumento da capacidade computacional e a popularização dos serviços em nuvem, possibilita a criação de melhores modelos.

Bughin et al. (2018) nos dá mais detalhes sobre como diversas empresas, ao redor do mundo, têm corrido contra o tempo para digitalizar sua operação e adotar técnicas de Inteligência Artificial, pois as empresas que saíram na dianteira dessa corrida, tornaram-se mais competitivas que as demais.

Marr (2020) nos dá um breve resumo da evolução do aprendizado de máquina, que se inicia em 1950 com o Teste de Turing. Em 1952, Arthur Samuel escreveu o primeiro programa de computador capaz de aprender a jogar Damas. O primeiro neurônio artificial foi proposto em 1957 por Frank Rosenblatt. De 1990 em diante, a abordagem passou a ser orientada a dados e não mais orientada ao conhecimento. O termo *Deep Learning* surge em 2006 com Geoffrey Hinton. De 2010 em diante, grandes empresas, como Microsoft e IBM, lançam plataformas e algoritmos próprios para aprendizado de máquina. De 2015 em diante, com a popularização e aumento da demanda por serviços

em nuvem, diversas empresas como Amazon, Google, IBM e Microsoft, começaram a disponibilizar plataformas e serviços ao público para uso sob demanda, tornando o uso de aprendizado de máquina mais acessível.

Oluyisola et al. (2020) apresenta o diagrama representado na figura 01, indicando o caminho e as etapas de modernização das empresas com o uso de tecnologias como internet das coisas, serviços em nuvem e aprendizado de máquina para tornarem-se orientadas a dados.



**Figura 01: caminho de modernização das empresas**

## 1.1 Relevância do Tema

Ludenir (2021) nos mostra como as empresas têm utilizado o conhecimento extraído destes dados para automação de diversas atividades, demonstrando alguns casos de sucesso com a aplicação de diferentes técnicas de Inteligência Artificial, nos mais variados segmentos de negócio, seja no desenvolvimento de carros autônomos, reconhecimento de imagem aplicada a diagnósticos de saúde, tradução de textos e de fala, sistemas de recomendação, etc.

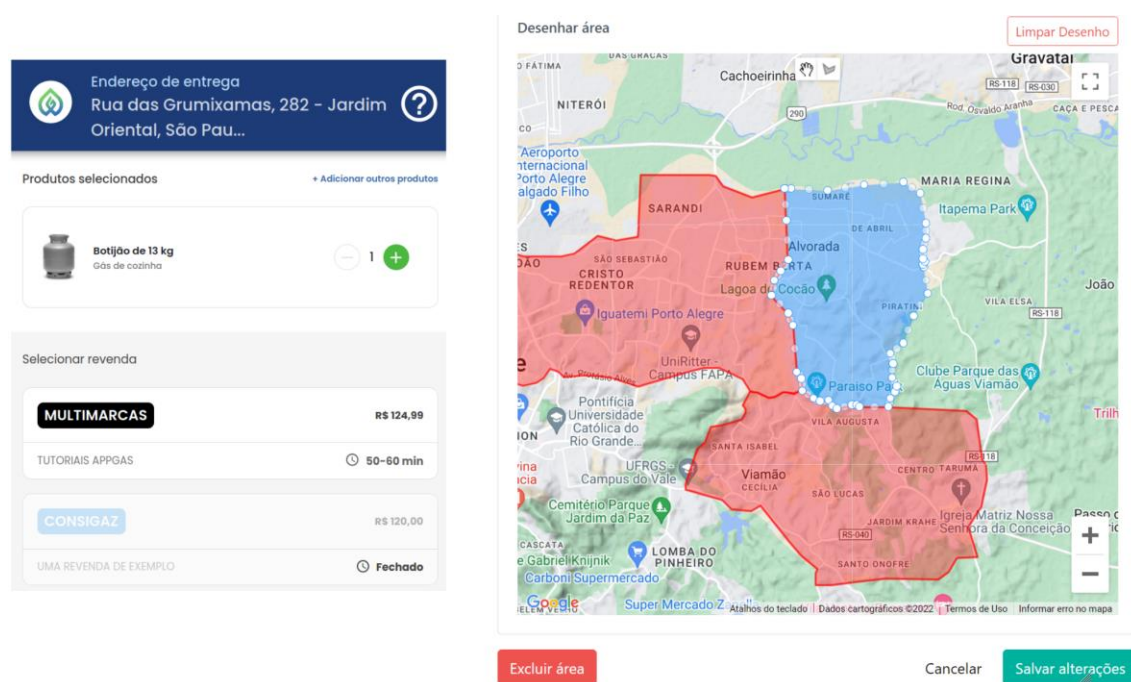
A empresa AppGás possui uma plataforma dedicada a venda de botijões de gás, para residências e restaurantes, onde vendedores de uma determinada região são capazes de cadastrar-se para anunciar seus produtos aos clientes da plataforma.

A empresa também disponibiliza um aplicativo para dispositivos móveis onde qualquer pessoa consegue fazer uma pesquisa, a partir de um endereço, para ver quais revendas de gás atendem na região do endereço informado, sendo possível fazer a compra, dentro da plataforma, dos produtos desejados, escolhendo o revendedor mais conveniente: o que entrega mais rápido, o melhor avaliado dentro da plataforma ou aquele com menor preço. É possível comprar mais de um produto de uma vez e todo o processo de entrega é realizado pelo vendedor. Os vendedores possuem acesso à plataforma e conseguem aceitar ou rejeitar pedidos feitos pelos clientes.

## 1.2 Problema da Pesquisa

Um dos desafios da empresa, é conseguir ser mais precisa ao informar o tempo estimado de entrega de um determinado revendedor, para um quando um cliente da empresa faz uma consulta na plataforma.

O tempo de entrega ( $M$ ) é a média da diferença de tempo entre o momento em que a revenda entregou o pedido e o momento em que a revenda aceitou o pedido, considerando todos os pedidos entregues nos últimos noventa (90) dias. A empresa sempre exibe um valor arredondado, em uma faixa de 10 minutos. A figura 02 demonstra duas capturas de tela: na esquerda, temos o aplicativo para dispositivo móvel, demonstrando a consulta de revendas disponíveis com a marca e valor do produto, juntamente com o tempo estimado de entrega; na direita, temos um exemplo da ferramenta de criação de áreas de atendimento, que é utilizada pelo administrador da revenda para informar em quais locais e horários atende, juntamente com a precificação dos produtos.



**Figura 02: consulta de revendas e criação de áreas de atendimento**

O problema do método atual, é que ele não leva em consideração diversos fatores que influenciam diretamente no tempo com que uma revenda é capaz de realizar a entrega de um pedido. Para ser mais assertivo, o cálculo deveria considerar, por exemplo, que o horário e/ou o dia da semana em que o pedido é realizado, tem influência no tempo de entrega, conforme mostrado por Moreira et al. (2005), pois o tráfego de veículos impacta na locomoção do entregador da revenda, de modo que o tráfego mais intenso de veículos típico de algumas faixas de horário, torna a entrega do pedido mais demorada. A distância entre o endereço físico da revenda e o endereço do cliente também influencia no tempo de entrega e não é levada em consideração neste cálculo.

### **1.3 Objetivos da Pesquisa**

O objetivo geral deste trabalho é avançar na gestão inteligente dos dados da plataforma para a criação de um modelo, com melhor estimativa que o modelo empregado atualmente pela empresa para a previsão do tempo de entrega de um pedido feito para um determinado revendedor sob determinadas condições. Com isso, aumentamos a confiabilidade da informação passada aos clientes finais da empresa, tornando-a mais competitiva.

Como objetivos específicos ou secundários, temos a aplicação de técnicas de aprendizado de máquina para entender a relevância de cada variável e seu impacto no tempo de entrega de um pedido, auxiliando a empresa na tomada de decisões. Temos também como objetivo secundário, a comparação de desempenho entre modelos tradicionais de aprendizado de máquina com modelos de aprendizagem profunda para a previsão do tempo de entrega.

### **1.4 Contribuições da pesquisa**

Este estudo espera trazer as seguintes contribuições:

- No âmbito acadêmico contribui com a exploração e comparação de técnicas e modelos de aprendizado de máquina tradicionais e de aprendizado profundo.
- Para a empresa, cria um modelo baseado em dados para melhores estimativas dos tempos de entrega.
- Para a sociedade, o trabalho ainda contribui com a disponibilização do código e dos dados utilizados para uso e estudos futuros.

## **2. Referencial Teórico**

Neste projeto, são empregados vários conceitos e técnicas de inteligência artificial, aprendizado de máquina e aprendizado profundo. Esta seção fornece uma breve revisão de cada um desses temas.

### **2.1 Aprendizado de Máquina (Machine Learning)**

"Aprendizado de máquina é um ramo da Inteligência Artificial e Ciência da Computação que foca no uso de dados e algoritmos que imitam a forma com que os seres humanos aprendem, com a acurácia sendo melhorada gradativamente", IBM Cloud Education (2020).

Envolve o uso de estatística e métodos de otimização que permitem com que conjuntos de dados sejam analisados em busca de padrões. Devido a natureza do algoritmo que se atualiza de forma autônoma, a taxa de erro é reduzida a cada execução, ou seja, o algoritmo é capaz de aprender a partir dos dados analisados.

Salian (2018), nos dá a definição de quatro tipos de modelos de aprendizado de máquina:

- Supervisionado: utiliza dados rotulados que contém um valor alvo, com o qual o algoritmo é capaz de avaliar sua estimativa;
- Não-Supervisionado: utiliza dados não-rotulados que o algoritmo usa para encontrar relações, extraindo variáveis e padrões por conta própria;

- Semi-Supervisionado: é o meio termo entre supervisionado e não-supervisionado, que utiliza uma pequena quantidade de dados rotulados reforçando uma grande quantidade de dados não rotulados;
- Aprendizado por Reforço: treina um algoritmo com um sistema de recompensas, provendo *feedback* quando o agente performa a melhor ação em um cenário particular.

Este trabalho utiliza dados rotulados com os tempos de entregas realizados, de modo que o modelo supervisionado de aprendizado de máquina é empregado para as previsões.

## 2.2 Aprendizado de Máquina Supervisionado

Para Nasteski (2017), a tarefa do algoritmo de aprendizado de máquina é encontrar padrões e construir modelos matemáticos, que são então avaliados com base na capacidade preditiva em relação às medidas de variância dos próprios dados. Os dados rotulados facilitam o entendimento dos modelos.

É dividido em dois tipos de tarefas:

- Classificação: analisa os dados de entrada e os classifica de acordo com uma classe pré-definida.
- Regressão: analisa os dados de entrada e prevê um valor numérico.

Almaghrebi et al. (2020), lista e compara a performance de algumas técnicas mais utilizadas para métodos de regressão: *Gradient Boosting*, Árvores de Decisão, *Random Forests* e *Support Vector Machines* (SVM).

Dada a natureza do problema, para as técnicas tradicionais de aprendizado de máquina serão utilizadas técnicas de regressão como árvores de decisão e *random forests*.

## 2.3 Seleção de Variáveis (Feature Selection)

Kuhn et al. (2018) demonstra ganho significativo de performance no treinamento de modelos após o uso de alguma técnica de seleção de variáveis ou redução de dimensionalidade. O objetivo geral, é entender quais variáveis têm mais impacto, eliminando ruídos e descartando variáveis que são irrelevantes para a previsão ou classificação do problema. Modelos com menos variáveis são mais interpretáveis e têm menos custo de treinamento.

Alguns modelos já possuem algum mecanismo de seleção de variáveis embutidos, Kuhn et al. (2018) e Seijo-Pardo et al. (2015) dividem as técnicas em três grupos:

- *Wrapper Methods*: utiliza um subconjunto de variáveis para determinar a importância de cada uma. Um novo subconjunto é avaliado a cada iteração até que se encontra um subconjunto otimizado.
- *Filter Methods*: avalia cada variável de maneira isolada, e seleciona aquelas que atendem a um determinado critério.
- *Ensemble Methods*, fazem a combinação de diversas técnicas de ranqueamento de variáveis, com objetivo de melhorar a seleção.

Identificar as variáveis mais relevantes para o tempo de entrega é importante pois essa informação pode ser utilizada na tomada de decisões estratégicas pela empresa.


Neste estudo, interessa não só a previsão dos tempos de entrega, mas também a identificação das variáveis mais preditoras.

## 2.4 Redes Neurais Artificiais e Aprendizado Profundo (Deep Learning)

Redes Neurais Artificiais e modelos de Aprendizado Profundo vem aos poucos substituindo os modelos tradicionais para a solução de diversos problemas.


Mitchell (1997) define as Redes Neurais Artificiais (ANN) como um modelo computacional inspirado pelo sistema nervoso dos seres humanos. As redes são formadas por camadas de nós, chamados de neurônios artificiais. Estes nós, recebem um conjunto de valores como entrada, que podem ou não serem a saída de outros nós, e produzem um valor único de saída, que pode ser utilizado para alimentar outros nós.

Chollet (2018) classifica o aprendizado profundo como uma subárea do aprendizado de máquina, conforme demonstrado na figura 03 e demonstra como as técnicas são baseadas em redes neurais artificiais com camadas ocultas e diferentes formas de conexão entre nós. Os artigos de LeCun et al. (2015) e Bengio et al. (2021), demonstram como as técnicas de aprendizado profundo eliminam a necessidade de pré-processamento dos dados e seleção de variáveis e dão detalhes de como as técnicas vêm sendo adotadas.



**Figura 03: Relação entre Inteligência Artificial, Aprendizado de Máquina e Aprendizado Profundo**

Goodfellow et al. (2016) detalha a Rede Neural *Feedforward* (FNN), que é o modelo mais simples de rede profunda, onde a informação flui somente em um sentido: a informação é passada para a camada seguinte, a partir dos nós de entrada, até que a camada com os nós de saída seja atingida. A figura 04 exemplifica a construção de uma Rede Neural *Feedforward* descrita por Rumelhart et al. (1994).



**Figura 04: Exemplo de Rede Neural Feedforward**

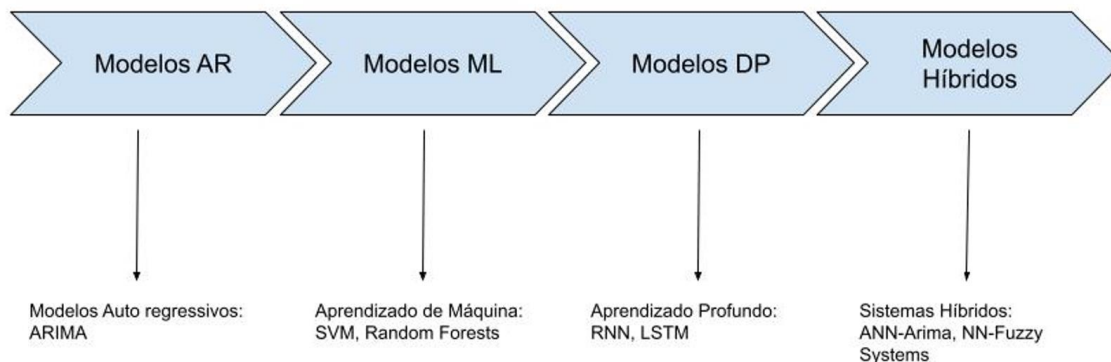
Raschka et al. (2019) apresenta a utilização das chamadas Redes Neurais Recorrentes (RNN) onde as conexões entre os diversos nós podem formar ciclos. Diferentemente das redes *feedforwards*, as redes recorrentes compartilham o mesmo peso entre todos os nós de uma mesma camada e cada camada recebe como entrada os valores de entrada iniciais e a saída da camada oculta do passo anterior.

A Rede Neural *Transformer* foi apresentada ao público por Vaswani et al. (2017), este tipo de rede que não utiliza recorrência, possui um mecanismo de atenção, que é capaz de detectar a influência de dados uns aos outros. Consegue processar os dados de entrada com o uso de paralelização, é considerado o estado da arte em aprendizado profundo e vem aos poucos substituindo redes neurais recorrentes em diversas tarefas.

Este trabalho empregará modelos de aprendizado profundo comparando seus resultados com os de modelos tradicionais de aprendizado de máquina. Dentro dos modelos de aprendizado profundo, redes recorrentes e transformers devem ser explorados.

## 2.5 Trabalhos correlatos

Já há algum tempo algoritmos de aprendizado de máquina vem sendo empregados também junto a modelos tradicionais, estatísticos, de previsão de séries temporais (ARIMA, SARIMAX etc.) (Rundo, 2019). Alguns desses trabalhos, empregados para a previsão de tempos de viagens, deslocamentos etc. e são relacionados a seguir. A figura 05 mostra um pouco desta evolução.



**Figura 05: linha do tempo das abordagens para previsão de séries temporais**

Moreira et al. (2005) aplica técnicas de regressão, entre elas *Random Forests* e *Support Vector Machines* para a previsão do tempo de viagem em transporte de passageiros na cidade do Porto, em Portugal. O trabalho conclui que para o problema apresentado e os dados utilizados para treinamento, a técnica *Random Forests* foi superior a técnica *Support Vector Machines*.

Servos et al. (2020), aplica *Support Vector Machines* e outras técnicas de regressão para a previsão do tempo de viagem em empresas de transporte multimodal de cargas. Neste trabalho, no entanto, a técnica *Support Vector Machines* se mostrou superior após ser treinada e comparada com as demais.

Joshi et al. (2017), descreve o uso de Árvores de decisão, Redes Neurais Artificiais e também técnicas de aprendizado profundo, como Redes Neurais Recorrentes para a previsão do tempo de deslocamento para corridas de táxi.

Lam et al. (2015) descreve em seu artigo o processo de seleção de variáveis e o uso de técnicas de regressão para a previsão do tempo de viagem em corridas de táxi, demonstrando que as técnicas utilizadas apresentaram bom desempenho.

### 3. Metodologia da pesquisa

Apresenta-se a seguir as tarefas e métodos previstos nesta pesquisa. Embora apresentadas em sequência, resultados de uma etapa podem requerer revisão de etapas anteriores que, muitas vezes, serão feitas em conjunto.

#### 3.1 Levantamento de Dados

Os dados utilizados no desenvolvimento do projeto são disponibilizados pela empresa em um arquivo no formato .CSV (*comma separated values*). Dados pessoais e dados sensíveis são removidos ou ofuscados por questões de confidencialidade. No momento os dados compreendem cerca de 1500 instâncias, compreendendo um período de noventa dias. A necessidade e utilidade de dados mais antigos será verificada ao longo do estudo. A tabela 01 apresenta uma amostra de alguns dos dados a serem empregados.



**Tabela 01: amostra dos dados brutos**

day	hour	week day	quantity	discount	holiday	time elapsed	distance	ongoing orders	average delivery time
1	10:43	thursday	1	false	false	23.4425	11.5334	0	37.2042
1	10:50	thursday	1	false	false	18.4596	2.1031	1	35.2382
1	18:35	thursday	1	false	false	46.1038	2.9548	0	33.1409
2	18:01	friday	1	false	false	65.6118	12.9826	0	34.5812
2	18:25	friday	1	false	false	104.9308	1.4949	1	37.6843

### 3.2 Revisão da literatura

Esta etapa tem como objetivo complementar a relação de artigos selecionados nesta fase (Moreira et al., 2005; Servos et al., 2020; Joshi et al., 2017; Lam et al., 2015). Serão selecionados novos artigos das bases de dados (Google Scholar, Scopus e Web Science. e/ou Semantic Scholar) que compreendam o uso de modelo de aprendizado de máquina tradicional e aprendizado profundo para estimativa de tempos, rotas ou valores, e explicabilidade dos modelos, e que possam contribuir com técnicas e *insights* para este estudo. Os trabalhos selecionados serão revisados e sumarizados.

### 3.3 Pré-processamento de dados

Nesta etapa é feito o entendimento mais detalhado dos dados. São, também, avaliadas e realizadas transformações dos dados. A fase de entendimento deve produzir um dicionário e uma caracterização dos dados. A fase de transformação pode envolver uma ou mais tarefas de: limpeza dos dados; tratamento de nulos; formatação e encode dos dados; normalizações; e criação de atributos derivados.

### 3.4 Seleção dos modelos

Esta etapa do projeto discute e seleciona, ao menos um modelo de aprendizado de máquina tradicional e um de aprendizado profundo, para aplicação desta pesquisa com base na revisão de artigos e estudos já realizados. Isso pode envolver implementações já realizadas, mas também sugestões apresentadas nos artigos.

### 3.5 Construção e treinamento de modelos

Nesta etapa são implementados e treinados os modelos. Os modelos são desenvolvidos em Python, preferencialmente com Jupyter notebooks. Para aprendizados de máquina tradicionais será empregada a biblioteca scikit-learn. Para aprendizado profundo pode-se empregar PyTorch ou Keras/TensorFlow, o que é definido mais adiante no desenvolvimento do projeto.

### 3.6 Comparação dos modelos

Aqui o resultado dos modelos é avaliado por diferentes perspectivas. Além do critério de menor erro de previsibilidade, aspectos como explicabilidade, sobreajuste, tempo e quantidade de dados requerida para o treinamento e economia do modelo devem ser considerados.

### 3.7 Identificação de relevância de variáveis

Cada modelo utilizado para treinamento faz seu próprio ranqueamento de variáveis que têm mais impacto no tempo de entrega e aquelas variáveis que são irrelevantes. A explicabilidade dos modelos é analisada a procura de *insights* que possam auxiliar a empresa na tomada de decisões.

### 3.8 Avaliação dos resultados

Aqui trata-se de avaliar o resultado do projeto como um todo. Qual o ganho obtido dos modelos empregados para o problema do negócio e sua viabilidade de implementação? Avalia-se também as limitações e melhorias da solução apresentada.

## 4. Cronograma

O cronograma a seguir apresenta as fases já realizadas e previstas no projeto.

**Tabela 02: cronograma**

Atividade	Mês											
	jul	ago	set	out	nov	dez	jan	fev	mar	abr	mai	jun
1. Levantamento de dados												
2. Revisão da literatura												
3. Pré-processamento de dados												
4. Seleção dos modelos												
5. Construção e treinamento de modelos												
6. Comparação dos modelos												
7. Identificação de relevância de variáveis												
8. Avaliação dos resultados												
9. Preparação de artigo para submissão												

## Referências

Boulic, R. and Renault, O. (1991) “3D Hierarchies for Animation”, In: New Trends in Animation and Visualization, Edited by Nadia Magnenat-Thalmann and Daniel Thalmann, John Wiley & Sons Ltd., England.

- Henke, N., Bughin, J., Chui, M., Manyika, J., Saleh, T., Wiseman, B. e Sethupathy, G. (2016), “The Age Of Analytics: Competing In A Data-Driven World”, McKinsey Global Institute.
- Bughin, J., Seong, J., Manyika, J., Chui, M. e Joshi, R. (2018), “Notes from the AI Frontier Modeling the Impact of AI On The World Economy”, McKinsey Global Institute.
- Marr, B. (2016) “A Short History of Machine Learning Every Manager Should Read”, Forbes. Disponível em <<https://www.forbes.com/sites/bernardmarr/2016/02/19/a-short-history-of-machine-learning-every-manager-should-read>>. Acesso em: 19/11/2022.
- Oluyisola, O. E., Sgarbossa, F. e Strandhagen, J. O. (2020) “Smart Production Planning and Control: Concept, Use-Cases and Sustainability Implications”. Disponível em <<https://doi.org/10.3390/su12093791>>. Acesso em 20/11/2022.
- LeCun, Y., Bengio, Y. e Hinton, G. (2015) “Deep Learning”, Nature, vol. 521, p. 436-444.
- Chollet, F. (2018) “Deep Learning with Python”, Manning Publications Co.
- Goodfellow, I., Bengio, Y. e Courville, A. (2016) “Deep Learning”, MIT Press.
- Kuhn, M. e Johnson, K. (2018) “Applied Predictive Modeling”, Springer, 2a. edição.
- Mitchel, T. M. (1997) “Machine Learning”, McGraw-Hill.
- Raschka, S. e Mirjalili, V. (2019) “Python Machine Learning: Machine Learning and Deep Learning with Python, scikit-learn and Tensorflow”, Packt Publishing Ltda, 3a. edição.
- Ludermir, T. (2021) “Inteligência Artificial e Aprendizado de Máquina: estado atual e tendências”. Disponível em: <<https://doi.org/10.1590/s0103-4014.2021.35101.007>>. Acesso em 09/11/2022.
- Seijo-Pardo, B., Bolón-Canedo, V., Porto-Díaz, I. e Alonso-Betanzos, A. (2015) “Ensemble Feature Selection for Rankings of Features”. Disponível em <[https://www.researchgate.net/publication/300786598\\_Ensemble\\_Feature\\_Selection\\_for\\_Rankings\\_of\\_Features](https://www.researchgate.net/publication/300786598_Ensemble_Feature_Selection_for_Rankings_of_Features)>. Acesso em: 18/11/2022.
- Rumelhart, D. E., Widrow, B. e Lehr, M. A. (1994) “The basic ideas in neural networks”, Communications of the ACM, vol. 37, p. 87–92. Disponível em: <<https://doi.org/10.1145/175247.175256>>. Acesso em 10/11/2022.
- Bengio, Y., LeCun, Y. e Hinton, G. (2021) “Deep Learning for AI”, Communications of the ACM, vol. 64, no. 7, p. 58-65. Disponível em: <<https://doi.org/10.1145/3448250>>. Acesso em 12/11/2022.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., Polosukhin, L. (2017) “Attention Is All You Need”, Advances in Neural Information Processing Systems. Disponível em: <<https://arxiv.org/abs/1706.03762>>. Acesso em 12/11/2022.
- Nasteski, V. (2017) “An overview of the supervised machine learning methods”. Disponível em:

- <[https://www.researchgate.net/publication/328146111\\_An\\_overview\\_of\\_the\\_supervised\\_machine\\_learning\\_methods](https://www.researchgate.net/publication/328146111_An_overview_of_the_supervised_machine_learning_methods)>. Acesso em 10/11/2022.
- Almaghrebi, A., Aljuheshi, F., Rafaie, M., James, K. e Alahmad, M. (2020) “Data-Driven Charging Demand Prediction at Public Charging Stations Using Supervised Machine Learning Regression Methods”, *Energies*, vol. 13, no. 16. Disponível em <<https://doi.org/10.3390/en13164231>>. Acesso em 19/11/2022.
- Salian, I. (2018) “SuperVize Me: What’s the Difference Between Supervised, Unsupervised, Semi-Supervised and Reinforcement Learning?”, NVIDIA Blog. Disponível em: <<https://blogs.nvidia.com/blog/2018/08/02/supervised-unsupervised-learning/>>. Acesso em 10/11/2022.
- Rundo, F., Trenta, F., di Stallo, A. L. e Battiato, S. (2019) “Machine Learning for Quantitative Finance Applications: A Survey”. Disponível em: <<https://doi.org/10.3390/app9245574>>. Acesso em 21/11/2021.
- Moreira, J. M., Jorge, A., Sousa, J. F. e Soares, C. (2005) “Trip Time Prediction In Mass Transit Companies. A Machine Learning Approach”, *Advanced OR and AI methods in transportation*. Disponível em: <<https://repositorio-aberto.up.pt/handle/10216/6749>>. Acesso em 09/11/2022.
- Servos, N., Liu, X., Teucke, M. e Freitag, M. (2020) “Travel Time Prediction in a Multimodal Freight Transport Relation Using Machine Learning Algorithms”, *Logistics* 2020. Disponível em: <<https://doi.org/10.3390/logistics4010001>>. Acesso em 08/11/2022.
- Joshi, N., Hotalappa, M. e Gadade, K. (2017) “A Study on Travel Time Estimation for Taxi Trips”, *International Education & Research Journal (IERJ)*, vol. 3. Disponível em: <<https://www.academia.edu/36968291>>. Acesso em 09/11/2022.
- Lam, H. T., Diaz-Aviles, E., Pascale, A., Gkoufas, Y. e Chen, B. (2015) “Taxi Destination and Trip Time Prediction from Partial Trajectories”, *arXiv*. Disponível em: <<https://arxiv.org/abs/1509.05257>>. Acesso em 09/11/2022.
- “Machine Learning”, IBM Cloud Education, 2020. Disponível em: <<https://www.ibm.com/cloud/learn/machine-learning>>. Acesso em 09/11/2022.